

自适应有限元方法对于求解具有不连续系数的椭圆问题的有效性

第五组：李东虔 路娜 孙宇乐 李霖峰

湘潭大学

数学与计算科学学院

2022 年 11 月 30 日

- 1 引言
 - 数学模型
 - 公式以及一些记号
 - 创新点之一——新的后验误差估计子
 - 其他
- 2 后验误差估计分析
 - 变分问题
 - 分析过程
- 3 自适应算法及其收敛性
 - 数据振荡项 + 精化策略
 - 一些引理
 - 其他
- 4 数值实验
 - 算例
 - 误差估计子的有效性
 - 参数 θ 的影响
 - 奇异点的影响

椭圆形微分方程：

$$-div(a(x)\nabla u) = f \quad in \Omega \quad (1)$$

$$u = 0 \quad on \partial\Omega \quad (2)$$

其中, Ω 是 $R^d (d=2,3)$ 中的多面体区域, 源项 $f \in L^2(\Omega)$, 系数 $a(x)$ 为分片常值函数, 且 $a(x) > 0$ 。

模型背景：复合材料中的稳态热传导，非均匀多孔介质中的多相流动等。

表 1: 符号说明

符号	含义
\mathcal{M}_H	区域 Ω 的正则三角剖分
K	$K \in \mathcal{M}_H$, 即某个三角单元
\mathcal{B}_H	所有 K 的内部边的集合
e	$e \in \mathcal{B}_H$, 即某个内边
Ω_e	$\cup_{e \in K_i} K_i$, 即共享边 e 的两个单元 K
H_K	单元 K 的直径
H_e	内边 e 的直径

公式以及一些记号

后验误差估计子 1(BM 法):

$$\eta_e^2 := \sum_{K \in \Omega_e} \|H_K f\|_{L^2(K)}^2 + \|H_e^{\frac{1}{2}} J_e\|_{L^2(\Omega)}^2 \quad (3)$$

其中, $J_e := \llbracket a \nabla u_H \rrbracket_e \cdot \nu$ 为跳量, ν 为 e 的单位法向量。跳量的出现是因为共享 e 的两个单元 K^+, K^- 中, $a \nabla u_H$ 是不连续的。对应的后验误差估计为:

$$\|u - u_H\|_{H^1(\Omega)}^2 \leq C \sum_{e \in \mathcal{B}_H} \eta_e^2 \quad (4)$$

其中, 常数 C 依赖于系数 $a(x)$, 当 $a(x)$ 在不同区域量级 $\frac{\max_{x \in \Omega} a(x)}{\min_{x \in \Omega} a(x)}$ 相差很大时, 这个后验误差估计将不准确。

公式以及一些记号

后验误差估计子 2(BV 法):

重新定义能量范数:

$$|||v|||_{\Omega} = \|a^{\frac{1}{2}} \nabla v\|_{L^2(\Omega)}$$

可导出新的后验误差估计子为:

$$\eta_e^2 := \sum_{K \in \Omega_e} \left\| H_K a_K^{-\frac{1}{2}} f \right\|_{L^2(K)}^2 + \left\| H_e^{\frac{1}{2}} a_e^{-\frac{1}{2}} J_e \right\|_{L^2(\Omega)}^2 \quad (5)$$

a_K 是 $a(x)$ 在单元 $K \in \mathcal{M}_H$ 上的常数值, 且 $a_e = \max_{K \in \Omega_e} (a_K)$ 。对应的后验误差估计为:

$$|||u - u_H|||_{\Omega}^2 \leq C \sum_{e \in \mathcal{B}_H} \eta_e^2 \quad (6)$$

其中, 常数 C 与系数 $a(x)$ 无关, 当 $a(x)$ 在不同区域量级变化时, 对 C 没有影响。要求: 系数函数 $a(x)$ 满足拟单调条件。

Remark

本文在此基础上进行了创新, 在后验误差估计子 2 中加入了一个修正系数。

公式以及一些记号

定义 1 (拟单调条件-quasi-monotone condition)

我们称 a_K 是关于点 x 的拟单调函数, 如果满足条件:
对于 $\forall K \subset \omega_x$, 都 $\exists K_{x,qm} \subset \omega_x$, 且 $K \cup C_x \subset K_{x,qm}$ 使得:

$$a_K \leq a_{K'} \quad \forall K' \subset K_{x,qm}, \quad K' \in \mathcal{M}_H.$$

若 x 是一个边界节点, 则额外要求 $meas_{d-1}(\partial K_{x,qm} \cap \partial \Omega > 0)$, 即每个极大值都与边界相邻。其中 $K_{x,qm}$ 为 Lipschitz set, $meas_{d-1}(\cdot)$ 为 $d-1$ 维的测度。

不满足拟单调条件的节点称为奇异点。

定义 2 (极大值-local maximum)

给定内点 x , 我们称在 K_i 处取得极大值, 且极大值为系数分布函数 $a(x)$ 在 K_i 处的取值:

如果 $a_{K_i} > a_{K_j}$ 对于任意与 K_i 有公共边的 $K_j \in \omega_x$ 均成立。

公式以及一些记号

拟单调举例，如图：




图 1: 拟单调例子

对于点 x :

(a) 中的极大值为 100，系数分布函数为拟单调的。

(b) 中的极大值为 100 和 10，系数分布函数不为拟单调的，因为有 2 个不相等的极大值。

(c) 中系数分布函数为拟单调的，因为极大值为 10 且在与边界相邻的单元片处取得。

(d) 中系数分布函数不为拟单调的，因为虽然只有 1 个极大值为 1，但不在与边界相邻的单元片处取得。

创新点之一——新的后验误差估计子

椭圆问题(1)和(2)的后验误差估计为:

$$|||u - u_H|||_{\Omega}^2 \leq C_1 \sum_{e \in \mathcal{B}_H} \eta_e^2 \quad (7)$$

其中, 常数 C_1 仅仅依赖于三角剖分 \mathcal{M}_H 的最小角。后验误差估计子为:

$$\eta_e^2 := \sum_{K \in \Omega_e} \wedge_K \left\| H_K a_K^{-\frac{1}{2}} f \right\|_{L^2(K)}^2 + \wedge_e \left\| H_e^{\frac{1}{2}} a_e^{-\frac{1}{2}} J_e \right\|_{L^2(\Omega)}^2 \quad (8)$$

其中, $\wedge_e = \max_{K \in \Omega_e} \wedge_K$ 。在远离奇异点的单元中 $\wedge_K = 1$ 。

1. 基于后验误差估计子，自适应算法的过程为

$$Solve \rightarrow Estimate \rightarrow Refine/Coarsen \quad (9)$$

2. 迭代终止准则。

算法(9)的终止准则是：如果对于给定的任意的 $\varepsilon > 0$ ，后验误差估计满足 $\sum_{e \in \mathcal{B}_H} \eta_e^2 \leq \varepsilon$ 时停止迭代。但是对于上述后验误差分析来说，有一个未知的常数 C_1 ，使得该终止准则不能使用。

采用方法：记 \mathcal{M}_k 为算法(9)在第 k 次迭代中产生的有限元网格， u_k 是对应的数值解， $\eta_k^2 = \sum_{e \in \mathcal{B}_k} \eta_e^2$ 是第 k 次迭代的后验误差估计。计算后验误差估计减少率 $\frac{\eta_k}{\eta_0}$ 则提供了相对误差 $\frac{\|u - u_k\|_{\Omega}}{\|u - u_0\|_{\Omega}}$ 的一些信息，故终止准则为：如果对于给定的任意的 $\varepsilon > 0$ ，后验误差估计满足 $\frac{\eta_k}{\eta_0} \leq \varepsilon$ ，计算中止。

3. 文章主要内容分布。

第二节证明了新的后验误差估计。

第三节根据文献【14】中的方法证明了利用新的后验误差估计子的自适应算法(9)的收敛性。特别地，证明了自适应算法的降低率取决于因子 $\max_{K \in \mathcal{M}_H} \wedge_K$ ，举反例证明这个因子不能去掉。

第四节数值实验。以二维问题为例证明了新的后验误差估计的正确性，讨论算法受参数 θ 的影响性，记录算法误差下降率受因子 $\max_{K \in \mathcal{M}_H} \wedge_K$ 的影响性。特别地，证明了对于所提出的自适应算法，网格和相关的数值复杂度都是近似最优的： $\|u - u_k\|_{\Omega} = CDOFs(k)^{-\frac{1}{2}}$ 和 $\|u - u_k\|_{L^\infty(\Omega)} = CDOFs(k)^{-1}$ 是有效渐进的，其中 $DOFs(k)$ 是网格 \mathcal{M}_k 的自由度。

- 1 引言
 - 数学模型
 - 公式以及一些记号
 - 创新点之一——新的后验误差估计子
 - 其他
- 2 后验误差估计分析
 - 变分问题
 - 分析过程
- 3 自适应算法及其收敛性
 - 数据振荡项 + 精化策略
 - 一些引理
 - 其他
- 4 数值实验
 - 算例
 - 误差估计子的有效性
 - 参数 θ 的影响
 - 奇异点的影响

变分问题

开集 $G \subset R^d$, $H^1(G)$ 表示 $L^2(G)$ 中函数的标准 *Sobolev* 空间, 它的一阶导数也在 $L^2(G)$ 中。范数 $||| \cdot |||_G$ 定义为 $|||v|||_G^2 = (a \nabla v, \nabla v)_G$, 当 $G = \Omega$ 时等价于 $H_0^1(\Omega)$ 范数。 $(\cdot, \cdot)_\Omega$ 表示 $L^2(G)$ 内积, 简记 $(\cdot, \cdot) = (\cdot, \cdot)_\Omega$ 。对于任意的 $f \in L^2(\Omega)$, 问题(1)和(2)的弱形式为:

$$u \in H_0^1(\Omega) : (a \nabla u, \nabla v) = (f, v) \quad \forall v \in H_0^1(\Omega). \quad (10)$$

V_H 是 \mathcal{M}_H 的线性有限元空间, 且 $V_0^H = V^H \cap H_0^1(\Omega)$ 。 $u_H \in V_0^H$ 是离散问题的解:

$$u_H \in V_0^H : (a \nabla u_H, \nabla v_H) = (f, v_H) \quad \forall v_H \in V_0^H. \quad (11)$$

对于任意的单元 $K \in \mathcal{M}_H$ 和边 $e \in \mathcal{B}_H$, 有

$$\omega_K = \cup \{K' \in \mathcal{M}_H : \bar{K}' \cap \bar{K} \neq \emptyset\}, \quad \omega_e = \cup \{K' \in \mathcal{M}_H : \bar{K}' \cap \bar{e} \neq \emptyset\}.$$

★

$$\Lambda_K := \begin{cases} \max_{K' \in \omega_K} \left(\frac{a_K}{a_{K'}} \right) & \text{if } K \text{ has one singular node.} \\ 1 & \text{otherwise.} \end{cases} \quad (12)$$

$$\eta_e^2 := \sum_{K \in \Omega_e} \Lambda_K \left\| H_K a_K^{-\frac{1}{2}} f \right\|_{L^2(K)}^2 + \Lambda_e \left\| H_e^{\frac{1}{2}} a_e^{-\frac{1}{2}} J_e \right\|_{L^2(\Omega)}^2 \quad (13)$$

其中, $\Lambda_e = \max_{K \in \Omega_e} \Lambda_K$.

Theorem 1

存在一个常数 $C_1 > 0$ 仅仅依赖于三角剖分 \mathcal{M}_H 的最小角, 使得成立

$$|||u - u_H|||_{\Omega}^2 \leq C_1 \sum_{e \in \mathcal{B}_H} \eta_e^2. \quad (14)$$

分析过程

Proof:

证明遵循标准后验误差分析中的论证。利用 robust 插值,

$r_H: H_0^1(\Omega) \rightarrow V_0^H$, 满足如下两个估计式:

$$a_K^{\frac{1}{2}} \|\phi - r_H \phi\|_{L^2(K)} \leq C \wedge_K^{\frac{1}{2}} H_K^{\frac{1}{2}} \|\phi\|_{w_K} \quad \forall \phi \in H_0^1(\Omega), \forall K \in \mathcal{M}_H, \quad (15)$$

$$a_e^{\frac{1}{2}} \|\phi - r_H \phi\|_{L^2(e)} \leq C \wedge_e^{\frac{1}{2}} H_e^{\frac{1}{2}} \|\phi\|_{w_e} \quad \forall \phi \in H_0^1(\Omega), \forall e \in \mathcal{B}_H. \quad (16)$$

远离奇异点处有 $\wedge_K = 1$, (10)减去(11)式再分部积分得: 对于任意的 $\phi \in H_0^1(\Omega)$, 有

$$(a \nabla(u - u_H), \nabla \phi) = \sum_{K \in \mathcal{M}_H} (f, \phi - r_H \phi)_K + \sum_{e \in \mathcal{B}_H} \int_e J_e(\phi - r_H \phi) ds \quad (17)$$

利用(15)可得

$$\begin{aligned} (f, \phi - r_H \phi)_K &\leq \|f\|_{L^2(K)} \|\phi - r_H \phi\|_{L^2(K)} \\ &\leq C \wedge_K^{\frac{1}{2}} \|H_K a_K^{-\frac{1}{2}} f\|_{L^2(K)} \|\phi\|_{w_K}. \end{aligned}$$

对任意的单元 $K \in \mathcal{M}_H$ 将上式相加，再利用网格的正则性估计，可得

$$\sum_{K \in \mathcal{M}_H} (f, \phi - r_H \phi)_K \leq C \left(\sum_{K \in \mathcal{M}_H} \Lambda_K \|H_K a_K^{-\frac{1}{2}} f\|_{L^2(K)}^2 \right)^{\frac{1}{2}} \|\phi\|_{\Omega}.$$

同理，利用(16)可得

$$\sum_{e \in \mathcal{B}_H} \int_e J_e(\phi - r_H \phi) ds \leq C \left(\sum_{e \in \mathcal{B}_H} \Lambda_e \|H_e a_e^{-\frac{1}{2}} J_e\|_{L^2(e)}^2 \right)^{\frac{1}{2}} \|\phi\|_{\Omega}.$$

在(17)中取 $\phi = u - u_H$ 。
即证。

Theorem 2

存在常数 $C_2, C_3 > 0$, 仅仅依赖于三角剖分 \mathcal{M}_H 的最小角, 使得对于任意的 $e \in \mathcal{B}_H$ 成立

$$\eta_e^2 \leq C_2 \wedge_e \sum_{K \in \Omega_e} \|u - u_H\|_K^2 + C_3 \wedge_e \sum_{K \in \Omega_e} \|H_K a_K^{-\frac{1}{2}}(f - f_K)\|_{L^2(K)}^2,$$

其中 $f_K = \frac{1}{|K|} \int_K f dx$, $\wedge_e = \max_{K \in \Omega_e} (\angle_K)$.

该定理证明见文献【19】。

分析过程

1. 因子 \wedge_e 不能去掉，具体见附录例子。
2. 在实际应用中，可能会有大量不同的奇异点。在这种情况下，在每次自适应迭代中，可能很难区分程序中的所有奇异点。那么就需要一个放大的后验误差估计：

$$\bar{\eta}_e^2 := \sum_{K \in \Omega_e} \bar{\Lambda}_K \left\| H_K a_K^{-\frac{1}{2}} f \right\|_{L^2(K)}^2 + \bar{\Lambda}_e \left\| H_e^{\frac{1}{2}} a_e^{-\frac{1}{2}} J_e \right\|_{L^2(e)}^2$$

其中， $\bar{\Lambda}_K = \max_{K' \in \omega_K} \left(\frac{a_K}{a_{K'}} \right)$, $\bar{\Lambda}_e = \max_{K \in \omega_e} \bar{\Lambda}_K$ ，在远离奇异单元上 $\bar{\Lambda}_K = 1$ 。

- 1 引言
 - 数学模型
 - 公式以及一些记号
 - 创新点之一——新的后验误差估计子
 - 其他
- 2 后验误差估计分析
 - 变分问题
 - 分析过程
- 3 自适应算法及其收敛性
 - 数据振荡项 + 精化策略
 - 一些引理
 - 其他
- 4 数值实验
 - 算例
 - 误差估计子的有效性
 - 参数 θ 的影响
 - 奇异点的影响

数据振荡项表达式：

$$\text{osc}(f, \mathcal{M}_H) := \left(\sum_{K \in \mathcal{M}_H} \|H_K a_K^{-\frac{1}{2}}(f - f_K)\|_{L^2(K)}^2 \right)^{\frac{1}{2}} \quad (18)$$

其中 f_K 表示 f 在单元 K 上的平均值，即 $f_K = \int_K \frac{f}{|K|} dx$.

Morin-Nochetto-Siebert(MNS)-refinement strategy

给定两个参数 $0 < \theta, \hat{\theta} < 1$,

- ① 选择内边 \mathcal{B}_H 的子集 $\hat{\mathcal{B}}_H$ 使得

$$\left(\sum_{e \in \hat{\mathcal{B}}_H} \eta_e^2\right)^{\frac{1}{2}} \geq \theta \left(\sum_{e \in \mathcal{B}_H} \eta_e^2\right)^{\frac{1}{2}}.$$

- ② 记 $\hat{\mathcal{M}}_H$ 是至少有一条边在 $\hat{\mathcal{B}}_H$ 中的所有单元的集合, 扩大 $\hat{\mathcal{M}}_H$, 使得

$$\text{osc}(f, \hat{\mathcal{M}}_H) \geq \hat{\theta} \text{osc}(f, \mathcal{M}_H).$$

- ③ 用这样的方法优化 $\hat{\mathcal{M}}_H$ 中的每个单元, 这样在单元内部就创建了节点。

通过 Galerkin 正交可以证明其收敛性。

一些引理

Lemma 1

如果 \mathcal{M}_h 是 \mathcal{M}_H 的局部细化, 使得 $V^H \subset V^h$, 那么下式成立:

$$|||u - u_h|||_{\Omega}^2 = |||u - u_H|||_{\Omega}^2 - |||u_h - u_H|||_{\Omega}^2.$$

Lemma 2

令 \mathcal{M}_h 是 \mathcal{M}_H 的局部细化, 那么存在常数 $C_4, C_5 \geq 1$, 仅依赖于网格 \mathcal{M}_H 的最小角度, 使得对于任意的 $e \in \hat{\mathcal{B}}_H$ 有

$$\eta_e^2 \leq C_4 \wedge_e \sum_{K \in \Omega_e} |||u_h - u_H|||_K^2 + C_5 \wedge_e \sum_{K \in \Omega_e} \|H_K a_K^{-\frac{1}{2}}(f - f_K)\|_{L^2(K)}^2 \quad (19)$$

其中, $\wedge_e = \max_{K \in \Omega_e} (\wedge_K)$.

一些引理

因为局部下界中因子 \wedge_e 的存在, 使得(19)式测量误差减小, 这对误差减少率有很大影响。 \wedge_e 在远离奇异点的两侧等于 1。

记 $\wedge = \max_{K \in \mathcal{M}_H} (\wedge_K)$, 把(19)式中的 $e \in \hat{\mathcal{B}}_H$ 相加可得

$$\sum_{e \in \hat{\mathcal{B}}_H} \eta_e^2 \leq 2C_4 \wedge |||u_h - u_H|||_{\Omega}^2 + 2C_5 \wedge \text{osc}(f, \mathcal{M}_H)^2.$$

根据精化策略第一步和定理 2 可以得到

$$\begin{aligned} |||u - u_H|||_{\Omega}^2 &\leq C_1 \sum_{e \in \mathcal{B}_H} \eta_e^2 \\ &\leq C_1 \theta^{-2} (2C_4 \wedge |||u_h - u_H|||_{\Omega}^2 + 2C_5 \wedge \text{osc}(f, \mathcal{M}_H)^2) \end{aligned}$$

即

$$|||u_h - u_H|||_{\Omega}^2 \geq \frac{\theta^2}{2C_1 C_4 \wedge} |||u - u_H|||_{\Omega}^2 - \frac{C_5}{C_4} \text{osc}(f, \mathcal{M}_H)^2.$$

根据引理 1, 可得

$$|||u - u_h|||_{\Omega}^2 \leq \alpha^2 |||u - u_H|||_{\Omega}^2 + \frac{C_5}{C_4} \text{osc}(f, \mathcal{M}_H)^2, \quad \alpha = \left(1 - \frac{\theta^2}{2C_1 C_4 \wedge}\right)^{\frac{1}{2}} \quad (20)$$

Lemma 3

记 $\gamma \in (0, 1)$ 是与一个细化步骤相关联的单元大小的缩减系数, 给定 $\hat{\theta} \in (0, 1)$, $\hat{\alpha} = (1 - (1 - \gamma^2)\hat{\theta}^2)^{\frac{1}{2}}$, \mathcal{M}_h 是根据 MNS 精化策略得到的网格 \mathcal{M}_H 的细化, 那么有

$$\text{osc}(f, \mathcal{M}_h) \leq \hat{\alpha} \text{osc}(f, \mathcal{M}_H). \quad (21)$$

基于这些引理以及性质(20), 可以得到如下减小误差的性质:

Theorem 3

记 $\beta \in \mathbf{R}$ 满足 $\max(\alpha, \hat{\alpha}) < \beta < 1$, 令

$$C_0 = (\|u - u_0\|_{\Omega}^2 + \frac{C_5}{C_4(\beta^2 - \min(\alpha, \hat{\alpha})^2)} \operatorname{osc}(f, \mathcal{M}_0)^2)^{\frac{1}{2}}.$$

那么利用局部后验误差估计子(13), 基于 MNS 精化策略的自适应算法产生了一个离散解的收敛序列 $\{u_k\}_{k \geq 1}$, 使得 $\|u - u_k\|_{\Omega} \leq C_0 \beta^k$.

一些引理

Proof:

记 $a_k = |||u - u_k|||_{\Omega}^2$, $b_k = \frac{C_5}{C_4} \text{osc}(f, \mathcal{M}_k)^2$,
由(20)和(21)可得

$$a_{k+1} \leq \alpha^2 a_k + b_k, \quad b_k \leq \hat{\alpha}^2 b_{k-1}. \quad (22)$$

重复利用(22)式的左边, 可得

$$\begin{aligned} a_{k+1} &\leq \alpha^2 (\alpha^2 a_{k-1} + b_{k-1}) + b_k \\ &= \alpha^{2 \cdot 2} a_{k-1} + \alpha^2 b_{k-1} + b_k \\ &\leq \dots \dots \dots \\ &\leq \alpha^{2(k+1)} a_0 + \sum_{j=0}^k \alpha^{2j} b_{k-j}. \end{aligned}$$

另一方面, 根据(22)式的右边, 对于任意的 $0 \leq j \leq k$, 有
 $b_{k-j} \leq \hat{\alpha}^{2(k-j)} b_0$, 则

$$\begin{aligned} a_{k+1} &\leq \beta^{2(k+1)} a_0 + \sum_{j=0}^k \alpha^{2j} \hat{\alpha}^{2(k-j)} b_0 \\ &\leq \beta^{2(k+1)} a_0 + \beta^{2k} b_0 \cdot \sum_{j=0}^k \left(\frac{\rho}{\beta}\right)^{2j} \\ &\leq \beta^{2(k+1)} a_0 + \beta^{2k} b_0 \cdot \frac{1}{1 - \frac{\rho^2}{\beta^2}} \\ &\leq \beta^{2(k+1)} \left(a_0 + \frac{b_0}{\beta^2 - \rho^2}\right). \end{aligned}$$

其中, $\rho = \min(\alpha, \hat{\alpha})$

即证。

一些 *Remark*:

1. 误差下降率 β 依赖于两个常数 $\alpha, \hat{\alpha}$, 一般的 $\gamma \leq \frac{1}{2}$; 根据引理 3 可推出如果 $\hat{\theta} = 2\sqrt{3}/5 \approx 0.6928$, 那么 $\hat{\alpha} \leq 0.8$, 这在涉及强奇异点的问题当中也是成立的。如何选择参数 θ 详见文献【14】, 本文讨论参数 θ 对误差大小的影响。
2. 误差下降率 β 对上界和下界常数 C_1, C_4 的乘积的依赖性 is 显然的, 这表明, 在基于新的后验误差估计的自适应过程中, 上界常数 C_1 的精确信息并不重要, 它是后验误差估计子所固有的, 决定着自适应算法的性能。

3. 误差估计(5), 有以下类似于(19)的局部下界成立:

$$\hat{\eta}_e^2 \leq \hat{C}_4 \sum_{K \in \Omega_e} |||u_h - u_H|||_K^2 + \hat{C}_5 \sum_{K \in \Omega_e} \|H_K a_K^{-\frac{1}{2}}(f - f_K)\|_{L^2(K)}^2$$

其中, $\hat{\eta}_e^2 = \sum_{K \in \Omega_e} \|H_K a_K^{-\frac{1}{2}}\|_{L^2(K)}^2 + \|H_e^{\frac{1}{2}} a_e^{-\frac{1}{2}} J_e\|_{L^2(e)}^2$, \hat{C}_4, \hat{C}_5 是仅仅依赖于网格 \mathcal{M}_H 最小角的正常数, 如果网格 \mathcal{M}_H 有奇异点, 那么上边界(6)变为

$$|||u - u_H|||_\Omega^2 \leq \hat{C}_1 \wedge \sum_{e \in \mathcal{B}_H} \hat{\eta}_e^2$$

其中, \hat{C}_1 仅仅依赖于网格 \mathcal{M}_H 的最小角。

4. 算法的局限性: 修正项 \wedge 的出现, 使得当系数变化较大时, 误差下降率 β 趋近于 1。方法虽然能够在控制误差的前提下, 提供了一种找到离散解的有效方法, 但是原问题的奇异性仍然没有改变。

- 1 引言
 - 数学模型
 - 公式以及一些记号
 - 创新点之一——新的后验误差估计子
 - 其他
- 2 后验误差估计分析
 - 变分问题
 - 分析过程
- 3 自适应算法及其收敛性
 - 数据振荡项 + 精化策略
 - 一些引理
 - 其他
- 4 数值实验
 - 算例
 - 误差估计子的有效性
 - 参数 θ 的影响
 - 奇异点的影响

算例

问题:

$$\begin{cases} -\operatorname{div}(a(x)\nabla u) &= f \quad \text{in } \Omega \\ u &= 0 \quad \text{on } \partial\Omega. \end{cases}$$

其中 $\Omega = (-1, 1)^2$, 在第一、三象限 $a(x) = R$, 第二、四象限 $a(x) = 1$, $f = 0$ 时, 方程的精确弱解 u 用极坐标表示为 $u(r, \vartheta) = r^\gamma \mu(\vartheta)$, 其中

$$\mu(\vartheta) = \begin{cases} \cos((\pi/2 - \sigma)\gamma) \cdot \cos((\vartheta - \pi/2 + \rho)\gamma) & \text{if } 0 \leq \vartheta \leq \pi/2 \\ \cos(\rho\gamma) \cdot \cos((\vartheta - \pi + \sigma)\gamma) & \text{if } \pi/2 \leq \vartheta \leq \pi \\ \cos(\sigma\gamma) \cdot \cos((\vartheta - \pi - \rho)\gamma) & \text{if } \pi \leq \vartheta \leq 3\pi/2 \\ \cos((\pi/2 - \rho)\gamma) \cdot \cos((\vartheta - 3\pi/2 - \sigma)\gamma) & \text{if } 3\pi/2 \leq \vartheta \leq 2\pi \end{cases}$$

算例

γ, ρ, σ, R 满足非线性关系

$$\begin{cases} R = -\tan((\pi/2 - \sigma)\gamma) \cdot \cot(\rho\gamma), \\ 1/R = -\tan(\rho\gamma) \cdot \cot(\sigma\gamma), \\ R = -\tan(\sigma\gamma) \cdot \cot((\pi/2 - \rho)\gamma), \\ 0 < \gamma < 2, \\ \max(0, \pi\gamma - \pi) < 2\gamma\rho < \min(\pi\gamma, \pi), \\ \max(0, \pi - \pi\gamma) < -2\gamma\sigma < \min(\pi, 2\pi - \pi\gamma). \end{cases} \quad (23)$$

解 $u \in H^{1+\delta}(\Omega)$, 且 $\delta < \gamma$, 对于非常小的参数 γ 是非常奇异的。

$$\gamma = 0.1, R \approx 161.4476387975881, \rho = \pi/4, \sigma \approx -14.92256510455152. \quad (24)$$

$$\gamma = 0.02, R \approx 4052.1806954768103, \rho = \pi/4, \sigma \approx -77.754418176347386. \quad (25)$$

$$\gamma = 0.5, R \approx 5.8284271247461907, \rho = \pi/4, \sigma \approx -2.3561944901923448. \quad (26)$$

算例




图 2: $\gamma = 0.1$ 时, 真解 u




图 3: 将区域均匀剖分成 2048 个小三角单元, 误差

$u - u_{2048}$

由图, 在奇异点周围相对误差是 23.68%, 能量误差范数

$\|u - u_{1024}\|_{\Omega} = 0.6954$, $\|u - u_{128}\|_{\Omega} = 0.8547$, 能量误差范数随着网格加密变化较小。根据标准有限元后验误差估计要想使能量误差范数小于 0.1, 每个空间方向的网格节点就至少为 10^{11} , 所以此时标准有限元方法就不适合此类问题 (带有强奇异点的椭圆问题)。但是, 自适应算法只需要 2793 个节点就能够使得能量误差范数达到 0.07303, 最大相对误差是 0.011719, 在奇异点附近低于 2%。

误差估计子的有效性

$\theta = 0.2$ 时，网格剖分情况。




图 4: 内点数 252




图 5: 内点数 1002




图 6: 内点数 2477

表 2: $\|u - u_h\|_{L^\infty} \leq 2 \times 10^{-2}$ 时 BM 和 NEW 方法的迭代次数、节点数、CPU 运行时间和最终误差

	k	n	CPUtime	$\ u - u_h\ _{L^\infty}$
<i>BM</i>	96	2175	189.27s	0.001998
<i>NEW</i>	38	155	6.788s	0.01941

误差估计子的有效性

$$\theta = 0.2, \gamma = 0.1$$




图 7: 比较 BM 和 NEW 方法的误差

参数 θ 的影响

取参数 $\gamma = 0.1$ ，分别取 $\theta = 0.1, 0.3, 0.5$ 。




图 8: $\theta = 0.1, 0.3, 0.5$ 时的误差

奇异点的影响

取参数 $\theta = 0.2$ ，分别取 $\gamma = 0.1, 0.5$ 。




图 9: $\gamma = 0.1, 0.5$ 时的误差

结论：当问题的奇异性变得较强时，误差下降率 β 接近于 1。

反例

在区间 $\Omega = (0, 2) \times (0, 2)$ 中，取：

$$a(x) = \begin{cases} 1 & x \in \Omega_1 \\ R > 1 & x \in \Omega_2 \end{cases}, \quad f(x) = \begin{cases} 0 & x \in \Omega_1 \\ 1 & x \in \Omega_2 \end{cases}$$

其中 Ω_1, Ω_2 如图所示。




图 10: 从左到右依次是：区域 Ω ，粗网格 \mathcal{M}_H ，细网格 \mathcal{M}_h

反例

在粗网格 \mathcal{M}_H 中, 即 FIG10 中间的网格, 有限元数值解满足:

$$(2 + 2R) u_1^H = \frac{1}{2}$$

解得:

$$u_1^H = \frac{1}{(4 + 4R)}$$

同时对于 FIG10 中边 e , 可以计算出 η_e^2

$$\eta_e^2 = \sum_{K \in \Omega_e} \Lambda_K \left\| H_K a_K^{-1/2} f \right\|_{L^2(K)}^2 + \Lambda_e \left\| H_e^{1/2} a_e^{-1/2} J_e \right\|_{L^2(e)}^2 = \frac{17}{16}$$

在细网格 \mathcal{M}_h 中, 有限元数值解满足:

$$\begin{bmatrix} 2+2R & -R & 0 \\ -R & 4R & -R \\ 0 & -R & 4R \end{bmatrix} \begin{bmatrix} u_1^h \\ u_2^h \\ u_3^h \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ \frac{7}{24} \\ \frac{1}{12} \end{bmatrix}$$

解得:

$$u_1^h = \frac{35}{8(15+13R)}, \quad u_2^h = \frac{9R+5}{4R(15+13R)}, \quad u_3^h = \frac{20R+15}{24R(15+13R)}$$

反例

对于边 e , 可以计算出 $\Lambda_e = R$, 且

$$\sum_{K \in \Omega_e} |||u_h - u_H|||_K^2 = \frac{(9R + 5)^2}{128(1 + R)(15 + 13R)^2}$$

容易算出极限

$$\lim_{R \rightarrow \infty} \frac{\eta_e^2}{\Lambda_e \sum_{K \in \Omega_e} |||u_h - u_H|||_K^2} = \frac{22984}{81}$$

这意味着 Λ_e 是不可忽略的, 并且在这个算例中是一个精确估计。

[1]Chen Z, Dai S. On the efficiency of adaptive finite element methods for elliptic problems with discontinuous coefficients[J]. SIAM Journal on Scientific Computing, 2002, 24(2): 443-462.

Thank you!